

Лабораторная работа № 1

1 Задание

- Выберите датасет, в котором есть атрибут, который «хочется предсказывать» (неважно, бинарный, категориальный или количественный он). Предварительно обработайте данные (разобраться с пропусками и т.п.). Разбейте выборку на обучающую и тестовую (можно «наивным» способом, хоть кроссвалидация действительно имеет место быть).
- Выявите статистически значимые факторы (сначала можно порисовать картинки, потом провести стат. тесты)
- Обучите какую-нибудь ML-модель на выявленных статистически значимых факторах
- Посмотрите, как оно работает на тестовой выборке

Задание звучит довольно-таки творчески, так что приведём конкретные требования, исходя из которых будет оцениваться само решение:

- Описана в общих чертах ML-модель или приведена ссылка на документацию/статью, откуда брали ML-модель.
- Для ML-модели выводится значение функции потерь на обучающей и тестовой выборках (вывод других метрик качества опционален).
- Как минимум два теста реализованы самостоятельно, причем должны выводиться статистика критерия, p-value, области принятия и критическая области. Минимальное количество уникальных применений стат. тестов – 4 (среди них 2 вызова самостоятельно реализованных тестов)
- Нужно выявить хотя бы 1 статистически значимый фактор