

Лабораторная работа № 3

Задание № 1

- Найдите обычную оценку максимального правдоподобия параметра θ , посчитайте теоретические смещение, дисперсию, MSE
- Найдите байесовскую оценку параметра θ для заданного семейства апостериорных распределений, найдите теоретические посчитайте теоретические смещение, дисперсию, MSE
- Проведите эксперимент для разных объёмов выборки, при каждом из которых много раз генерируйте параметр, считайте ОМП и байесовскую оценку, далее считайте эмпирические смещения, дисперсию, MSE.
- Постройте credible interval equal tailed and high density

Варианты (сначала указывается likelihood, потом – prior, затем параметры prior для эксперимента). Номер варианта вычисляется как целая часть от среднего арифметического порядковых номеров первых букв фамилий в кириллице по модулю 2 плюс один:

1. $\text{Pois}(\theta)$; $\Gamma(k, \lambda)$; $\lambda = k = 1$
2. $\text{Exp}(\theta)$; $\Gamma(k, \lambda)$; $\lambda = k = 1$ (тут используйте для экспоненциального закона параметризацию плотности в виде $p(x) = \theta^{-1}e^{-x/\theta}$, а для гамма распределения аналогично $p(x) = \frac{\lambda^{-\alpha} x^{\alpha-1} e^{-x/\lambda}}{\Gamma(\alpha)}$)

Задание № 2

- Выберите датасет, в котором есть категориальный атрибут, который «хочется предсказывать»
- Выберите набор независимых атрибутов (можно это проверить с помощью стат. тестов), от которых может зависеть категориальная переменная
- Разбейте набор атрибутов из предыдущего пункта на хотя бы 2 подкласса (необязательно не пересекающихся). Обозначим данные подклассы как C_k
- Разбейте выборку на обучающую и тестовую. На обучающей обучите хотя бы 2 наивных байесовских классификатора на подклассах C_k . На тестовой выборке посчитайте ассурсу (при желании можете выводить другие метрики)
- *Optional.* Для каждой обученной модели на тестовой выборке оцените логарифм произведения правдоподобия модели на априорную вероятность модели относительно обученных моделей (можно считать распределение моделей равномерным)

Hint: Пусть $data$ есть тестовый набор, состоящий из строк вида $(y_i, x_{i,1}, \dots, x_{i,m})$, и рассматриваем конкретную $model$. Тогда при предположении независимости строк правдоподобие для модели можно записать в виде $\prod_i P(y_i, x_{i,1}, \dots, x_{i,m} | model)$. По принципу произведения вероятностей получаем

$$P_{model}(y_i, x_{i,1}, \dots, x_{i,m}) = P_{model}(y_i) \cdot P_{model}(x_{i,1}, \dots, x_{i,m} | y_i)$$